



穆芳铭

AI大模型应用开发工程师
/ AIGC工程师

在 读

1445450620@qq.com

上海市浦东新区

2002/04

18530362073

个人技能

- 大模型与 Agent 架构**: 精通 LangChain / LangGraph 框架, 熟练构建 DAG 状态机与多轮对话系统; 深入理解 RAG 架构, 具备混合检索 (BM25+Vector) 与重排 (BGE-Reranker) 的工业级落地经验; 熟练运用 CoT (思维链) 与 Prompt 调优。
- AI 工程化与研发效能**: 深度践行 Spec-Driven Development, 擅长通过 OpenSpec 引导 LLM (Gemini/GLM-4) 进行自动化代码生成; 熟悉 TDD/BDD 测试驱动开发及 Agent 链路 Mock 测试; 掌握 Ragas 自动化评测体系。
- 后端与全栈开发**: 精通 Python, 熟练使用 FastAPI / Flask 构建高性能 API; 掌握 Pandas 数据处理引擎; 熟练使用 Vue3、Uni-app 及 Streamlit 进行前后端闭环开发; 熟悉 Git、Docker 及自动化 CI/CD 流程。
- 深度学习与算法**: 扎实的算法功底, 熟练掌握 PyTorch 及 CNN/Transformer 网络结构; 在计算机视觉 (行人重识别 Re-ID) 领域有深入研究及一作期刊论文产出。

工作经验

上海有孚网络科技有限公司

AI 应用研发实习生

2025/09 - 2026/05

- 项目经历**: 智孚企业服务平台 (ZhiFu Platform)
 - 背景**: 深度集成 OA 的企业级服务小程序, 个人负责从后端 (FastAPI) 到移动端 (Uni-app) 的全栈架构与开发。
 - 技术栈**: Python (FastAPI), Vue (Uni-app), Pandas, GLM-4/Gemini API, BDD Testing
 - AI 驱动研发提效 (核心贡献)**: 探索并主导落地“需求-规范-代码”的 AI 自动化研发链路。个人专注于系统架构设计与核心 API 定义 (OpenSpec), 利用 Gemini CLI 与 GLM-4 辅助完成超 80% 的业务逻辑生成, 使整体开发效率较传统模式提升约 60%。
 - 全栈架构与生态集成**: 基于 Uni-app + FastAPI 独立完成该企业级小程序的全栈构建。封装高可用 EcologyClient, 实现与上游核心 OA 系统 (Ecology) 的深度集成, 完成复杂 XML/JSON 转换与身份映射, 打通企业内网工单流转与权限审批闭环。
 - 高性能后端与质量保障**: 利用 Pandas 引擎重构后端个人中心及资产统计模块, 并引入智能缓存机制, 大幅降低接口延迟。构建基于 BDD (行为驱动开发) 的完整测试体系, 通过 Mock 技术实现零 Token 消耗的状态机跳转验证, 确保线上交付零客诉。

项目经历

企业级智能 IT 运维与入职 Agent 系统 核心独立开发者

2026/04 - 至今

https://github.com/FangmingMu/Intelligent_Onboarding

- 项目描述**: 针对企业内网信息过载与 IT 运维人力成本高的问题, 从 0 到 1 构建基于 LangGraph 的下一代“文档驱动型”智能 Agent 系统, 实现从语义检索到受控执行的全链路自动化闭环。
- 技术栈**: LangGraph, FastAPI, 混合检索 (BM25+Vector), BGE-Reranker, Ragas, SQLite

- **基于 LangGraph 的架构重构与状态控制**：摒弃传统 Agent 脆弱的“While 循环”黑盒调用，采用 **LangGraph** 将系统重构为可控的 DAG (有向无环图) 状态机。结合 Pydantic 进行强类型运行时校验 (Runtime Validation)，确保多轮复杂交互下 LLM 工具调用的绝对准确，首字响应时间 (TTFT) 稳定在 1s 左右。
- **工业级 Hybrid RAG 与质量量化评测**：抛弃单一向量检索，构建 **BM25 (词汇召回) + Vector (语义召回) + BGE-Reranker (二阶段精排)** 的工业级混合检索架构，彻底解决内网专有名词（如 IP、VPN-GW）召回痛点。引入 **Ragas 评测框架** 构建自动化打分看板，将核心指标 Context Recall 从 0.45 跃升至 0.90。
- **人类在环 (Human-in-the-loop) 设计**：针对高危权限申请及 P0 级工单，创新性设计“人类在环”挂起审批机制。利用 SQLite Checkpointer 实现对话状态的跨 Session 断点续传。在 500 人规模场景压测中，自动拦截 68% 的基础问询，工单响应由 4 小时缩短至 20 秒。

AIGC 创意工程与全栈应用探索

个人开源实践

2026/03 - 2026/04

- **AI 私人定制健身助手 (产品商业化闭环)**：基于 Streamlit 与 Qwen 3.5 构建，采用 Python threading 实现大模型流式响应的**后台多线程异步调度**，解决 UI 阻塞问题。设计了“智能模糊预览 + 激活码引流”的商业化机制，并集成 PushPlus 邮件通道实现高优线索秒级触达。
- **多源新闻流 Agentic Workflow**：设计了基于**多步思维链 (CoT)** 的自动化内容生成管线。通过“抓取->翻译初稿->事实核对->爆款标题”四步 Prompt 链，实现大模型对海外足球新闻的自动化采集、配图与改写发布，验证了大模型在流水线作业下的稳定性。

Re-ID算法优化与数据集构建

第一作者 | 期刊在投

2024/09 - 2025/06

- **技术栈**：PyTorch, CNN/Transformer, 损失函数设计 (Fusion-Loss), 数据集构建
- **项目描述**：针对监控场景中因遮挡及跨域分布差异 (Domain Gap) 导致的 Re-ID 准确率瓶颈，进行算法级优化与高质量数据集的建设。
- **核心职责与成果**：
 - **算法创新与 Loss 优化**：基于 PCB (Part-based) 架构设计混合特征模型 (MFM)。创新性地提出 **Fusion-Loss** 联合优化机制，将其与随机擦除数据增强 (REA) 策略深度融合，显著增强了模型对遮挡情况下的局部特征提取与对齐能力。
 - **开源基准数据集构建**：独立主导构建了具备多季节（春/冬）与多模态子域（行人/骑行者）的大型 Re-ID 基准数据集 **LSMS PB**，有效填补了现有开源数据集在真实场景跨域适应性 (Domain Adaptation) 研究上的数据空白。
 - **模型压测与论文产出**：依托 PyTorch 完成模型端到端训练与调参，在 Market-1501 等公开数据集上实现 Rank-1 达 93.29%、mAP 达 81.75%，相较基线模型大幅提升 10%。相关研究成果以第一作者身份撰写学术论文并投稿至知名学术期刊 (Under Review)。

教育经历

上海第二工业大学硕士在读

计算机技术 · 硕士

2024/09 - 至今

黄河科技学院

计算机科学与技术 · 本科

2020/09 - 2024/06